FOUR STUDY TRACKS · ONE COMPLETE SYSTEM

Team Defense Guide

Русское пособие с проверяемыми фактами, английскими репликами, упражнениями, вопросами экзаменатора и репетицией на 15 минут.

Проект за одну минуту

Calcio Champagne — воспроизводимая система футбольных данных: она проверяет связь расходов на трансферы с изменением атакующего индекса в следующем сезоне и с итоговым местом. Сравнение добавляет голы за/против, разницу, ранги, реальные удары, удары в створ и угловые, а также описательные Poisson-оценки атаки и обороны. Поля провайдера xG нет; отдельно показана только экспериментальная оценка по ударам в створ, не настоящая xG. Сверка вратарских данных и связь красных карточек с пропущенными сопровождаются покрытием и ограничениями. Лицензия основного набора Transfermarkt остаётся неподтверждённой.

> **Новые показатели сравнения.** GF — забитые голы; GA — пропущенные; GD = GF−GA. Атакующий ранг строится по голам за матч (чем больше, тем выше место), защитный — по пропущенным за матч (чем меньше, тем выше место). Ранг считается отдельно внутри выбранных лиги и сезона; ничьи делят место. xG отсутствует в загруженной схеме, его нельзя выводить из счёта.

План подготовки команды

1. Каждый изучает свою карточку, проходит упражнения и показывает, где подтверждение в репозитории.
2. Вместе проследите CSV → PostgreSQL → pipeline → API → экран.
3. Проведите 15-минутную репетицию с таймером; не превышайте время своей части.
4. Каждый отвечает минимум на два вопроса вне своего направления.
5. Проверьте приложение на другом ноутбуке и подготовьте резервное видео.

> **Распределение в пособии — план изучения и выступления.** Оно само по себе не доказывает, кто писал конкретный код. На защите описывайте фактическую работу, которую вы можете показать.

Данные и PostgreSQL

Область: Источники → валидация → COPY → схема и SQL

Что знать

- Какой снимок данных используется: sources.json, закреплённая ревизия и SHA-256; чем загруженный файл отличается от Git LFS pointer.
- Единица наблюдения: клуб × сезон × соревнование. Отображаемое имя не является ключом.
- Почему PostgreSQL соответствует фиксированным столбцам и связям; почему COPY быстрее построчных INSERT для этой загрузки.
- Что делает индекс (team_id, season_name, competition_id), почему он создаётся после COPY и зачем нужен ANALYZE.
- Опциональность football-data.co.uk, сопоставление названий клубов, проверка счетов и борьба с дубликатами.
- Лицензия первичного источника пока не подтверждена; публичная скачиваемость не доказывает открытую лицензию.

Что показать

1. Открыть loader/sources.json: ревизия, URL, SHA-256 и порядок столбцов одного источника.
2. Показать ключ агрегации в sql/champagne_queries.sql и объяснить MAX(team_name) как выбор подписи.
3. Показать пример ошибочного счёта/дубликата в tests/test_match_loader.py и ожидаемое поведение.

Английская реплика для репетиции

> *Our data layer uses eleven pinned CSV tables. We chose PostgreSQL because the records have fixed schemas and are joined by player, club, competition and season. The loader validates headers, uses COPY for bulk import, and builds indices afterwards. We aggregate by canonical identifiers so name aliases do not duplicate observations. An optional match source adds actual scorelines and standings. Invalid or duplicate matches are handled explicitly. The source is publicly downloadable, but its licence is still unconfirmed; we do not claim that this requirement is resolved.*

Передача слова: “With the data stored consistently, the next step is to define a valid season-to-season target and evaluate it.”

Практика

1. Объясни, почему две строки с разными названиями одного клуба нельзя считать двумя наблюдениями.
2. На бумаге проследи 0–0, будущий матч без FTR и два противоречивых счёта одного матча.

3. Запусти тесты загрузчика и объясни причину каждого отказа, не ограничиваясь словом validation.

Как закрывать экзамен

1. Ты открываешь защиту: слайды 1–3, 00:00–03:45. Темп всей команды задаёшь ты — не разгоняйся, первые 20 секунд говори медленно.
2. Начни с вопроса, понятного вне курса, и сразу раздели два вопроса: динамика следующего сезона и описательная связь в том же сезоне.
3. Открой `loader/sources.json` на экране и покажи один реальный элемент манифеста: ревизию, SHA-256 и порядок столбцов. Это сильнее любого слайда.
4. Про лицензию говори первой, до вопроса экзаменатора: ревизия закреплена, лицензия не подтверждена, сырые данные не распространяем.
5. Про legacy metadata table тоже скажи сама: одна таблица отличается от свежей нормализованной загрузки, в центральный индекс и модель она не входит.
6. Обоснование PostgreSQL держи в одном предложении: фиксированные столбцы и связи по игрокам, клубам, сезонам и соревнованиям.
7. Передай слово по скрипту `handoff_en` — не импровизируй переход, это съедает секунды.

Где смотреть в проекте

Файл в проекте	Что в нём смотреть
`loader/sources.json`	Закреплённая ревизия, URL, SHA-256 и порядок столбцов каждого из 11 источников. Открывай этот файл, а не рассказывай про него словами.
`loader/get_data.py`	Проверка заголовков и контрольной суммы, временный файл и атомарная установка — ответ на вопрос про обрыв загрузки.
`loader/load_data.py`	COPY в PostgreSQL, валидация матчей, `parse_match_extras`, очистка устаревшего enrichment при пропавшем источнике.
`sql/schema.sql`	Схема, индексы и аддитивные ALTER для новых столбцов матчей: существующая база обновляется без потери загруженных счетов.
`sql/champagne_queries.sql`	Ключ агрегации клуб × сезон × соревнование и MAX(team_name) как выбор подписи, а не ключа.
`sql/team_name_map.sql`	Сопоставление названий клубов с каноническими идентификаторами перед join матчей.
`tests/test_acquisition.py`	Что именно проверено в загрузке: плохой хэш, плохой заголовок, обрыв передачи — на фиктивных HTTP-ответах.
`tests/test_match_loader.py`	Дубли и противоречивые счета, двух- и четырёхзначные годы, валидные 0–0.
`docs/SOURCES.md`	Провенанс, расхождение legacy metadata table и граница лицензии — твой ответ на лицензионный вопрос.

Избегай

- Все источники имеют открытую лицензию.
- Индекс ускоряет любой запрос в 145 раз.
- Ноль в данных всегда означает подтверждённое отсутствие события.

LILLLAZ · 3:45 RECOMMENDED SPEAKING TIME

Аналитика и модель

Область: Индекс → признаки → target → baseline → ограничения

Что знать

- Формула Champagne Index; почему goal + assist может учитывать одно взятие ворот дважды и не является xG.
- Target = индекс следующего последовательного сезона минус текущий; минимум 30 матчей для топ-5 лиг и 5 для прочих соревнований.
- Пять признаков: текущий индекс, общие расходы, расходы на атаку, средний возраст, изменение средней рыночной стоимости.
- Как устраняется неверный лаг: уникальный клуб-сезон, точный предыдущий год, затем присоединение соревнований.
- Хронологический holdout: ранние сезоны обучают, поздние тестируют; baseline предсказывает нулевое изменение.
- R^2 = 0.127 не означает 87% или 12.7% точности. MAE 0.4856 против 0.5114 показывает небольшое улучшение.
- Lab использует отдельную модель на всех допустимых данных и не доказывает причинный эффект изменения бюджета.
- The season comparison also shows score-derived goals for/against/difference and per-match attack/defense ranks. These are separate from the Transfermarkt-based Champagne Index.
- The defensive-spend follow-up correlates defender fees with next-season change in goalkeeper-source goals conceded per match: r=0.0040, p=0.427, n=38,531; no useful linear signal.

Что показать

1. Показать текущие r, p, n и MAE на странице Project; назвать единицы и выборку каждого показателя.
2. Объяснить, почему 23/24 → 25/26 не является корректной парой, даже если shift(-1) её возвращает.
3. Поменять один ввод в Lab, вернуть baseline и объяснить, что измеряется сравнением сценариев.

Английская реплика для репетиции

> *We define attacking output as recorded goals plus assists per source match. The target is the change in that index in the next consecutive season. We remove incomplete season pairs and construct lagged squad values before joining competitions. Evaluation uses earlier seasons for training and later seasons for testing. The RandomForest has a test MAE of about 0.486, compared with 0.511 for predicting no change: an improvement of roughly five percent. This is a modest signal. The comparison also separates the Transfermarkt attacking index from completed league scores: goals for, goals against, their difference, and per-match attack and defense ranks. A defensive-spend follow-up also has almost zero association with next-season conceded-goal change (r=0.004, p=0.427; n=38,531). The Lab uses a separate all-data model for retrospective exploration. Moving a budget slider changes a model input; it does not establish what a transfer would cause.*

Передача слова: “The application makes those distinctions visible and lets us inspect the evidence for individual clubs.”

Практика

1. Рассчитай (76 + 70) / 38 и объясни, почему ответ 3.84 не равен голам за матч.
2. Посчитай (0.511364 − 0.485593) / 0.511364 ≈ 5.04% и назови правильную интерпретацию.
3. Различи три вопроса: корреляция в текущем сезоне, изменение в следующем сезоне и причинный эффект покупки игрока.

Как закрывать экзамен

1. Твои слайды 4, 5 и 7 (03:45–07:30 и 10:15–11:15). Между ними выступает Джакоппо с демо — следи за таймером, чтобы не потерять свой слайд findings.
2. Сначала определи наблюдение, потом показывай модель: клуб × сезон × соревнование, затем target как разницу с следующим последовательным сезоном.
3. Главное число произноси как сравнение, а не как достижение: MAE 0.4856 против baseline 0.5114 — улучшение около 5%.
4. Сразу объясни, что $R^2 = 0.127$ не доля правильных прогнозов. Это самый вероятный вопрос по твоей части.
5. Если спросят про Lab: отдельная модель на всех данных для исследования, её собственная подгонка не является независимым тестом.
6. Про любую связь говори «accompanies», «is associated with». Слово «causes» на твоей части стоит дороже всего.
7. Про xG отвечай коротко: поля провайдера нет, есть реальные удары и экспериментальный прокси по ударам в створ.

Где смотреть в проекте

Файл в проекте	Что в нём смотреть
`pipeline/compute_predictions.py`	Target, пять признаков, лаг рыночной стоимости, хронологический holdout и baseline нулевого изменения — всё в одном файле.
`docs/LAB.md`	Протокол модели и отличие Lab-модели (все данные) от оценочной модели (ранние сезоны → поздние).
`docs/findings.md`	Актуальные r, p, n, R^2 и MAE. Называй числа отсюда, а не по памяти.
`docs/GLOSSARY.md`	Определения Champagne Index, Discipline Index, рангов и граница xG.
`pipeline/feature_correlations.py`	Матрица корреляций признаков и флаг коллинеарности $\|r\| >$ порога.
`pipeline/shap_analysis.py`	mean |SHAP| на том же held-out сплите, что и R^2 — ответ на «почему не in-sample».
`pipeline/power_ratings.py`	Poisson attack/defense с общим home advantage; в коде прямо написано, что оценка in-sample.
`pipeline/proxy_xg.py`	Прокси по ударам в створ и finishing/defensive luck — почему это не xG.
`pipeline/discipline_effect.py`	Связь красных карточек с пропущенными: +0.341 гола за матч, 1 619 против 16 195 наблюдений.
`tests/test_regressions.py`	Зафиксированные известные дефекты модели и расчётов, чтобы они не вернулись.

Избегай

- Модель доказывает, что увеличение бюджета улучшит игру.
- R^2 — доля правильных прогнозов.
- Оценка отдельной holdout-модели является результатом тестирования all-data модели Lab.

JACOPOSCACCIANOCE · 3:45 RECOMMENDED SPEAKING TIME

API и интерфейс

Область: API → состояние страницы → сравнение → сценарии → демо

Что знать

- Почему FastAPI читает подготовленные таблицы вместо выдачи миллионов исходных строк в браузер.
- Состояние league/season/teams в URL; проверка параметров, read-only pool и ограничение времени SQL-запроса.
- Как считается очное сравнение с позиции каждого клуба: дома/в гостях меняются goals_for и goals_against.
- При отсутствии матчевого CSV показывается отсутствие покрытия; это не доказательство отсутствия встреч и не 0–0.
- Как Lab получает точные пять входов для клуба/сезона/соревнования, ограничивает attacking_spend общим бюджетом и отбрасывает устаревшие ответы.
- Что проверяют unittest, live API checks и реальный браузер; как читать /api/health и почему наличие одной таблицы недостаточно.
- Serie A 24/25 comparison: Inter 79 GF, 35 GA, +44 GD, attack rank 1 and defense rank 2; Milan 61, 43, +18, attack rank 3 and defense rank 7. Ranks are by per-match scored/conceded goals in the league-season.
- xG is absent from the actual loaded match schema. Do not infer it from goals or player aggregates.
- The optional player source has goalkeeper conceded totals. They exactly match the actual scoreboard GA in 366 of 388 complete top-five club-seasons; clean-sheet totals agree in 269. The UI uses actual scorelines for league ranks.

Что показать

1. Выбрать Serie A 24/25, открыть Inter/Milan и показать 1–2, 1–1, суммарные голы 2–3.
2. Показать, что без обогащения интерфейс даёт понятное сообщение, а не выдуманные значения.
3. Открыть Lab, изменить один вход, дождаться ответа и выполнить Reset. Не тратить время демо на все слайдеры.

Английская реплика для репетиции

> *The browser reads a bounded API over prepared results. League and season filters are explicit, and the URL preserves the selected scope. In the comparison, season totals and actual head-to-head meetings are separate. Serie A 24/25 shows Inter at 79 for and 35 against (+44), ranked first in goals scored per match and second in goals conceded per match. Milan has 61 for and 43 against (+18), ranked third and seventh. The source has no xG field. For Inter and Milan in 24/25, the recorded league scores are 1–2 and 1–1, giving head-to-head goals of two to three. Missing match enrichment is reported explicitly. The Lab loads the five real club-season inputs, calls a saved model and rejects invalid budgets or non-finite numbers. We verify behavior at three levels: regression tests, live data contracts and desktop/mobile browser checks.*

Передача слова: “The final question is whether this system runs reproducibly and what resources it uses.”

Практика

1. Поменяй клубы местами в URL и объясни, какие метрики должны поменять столбцы, а какие остаться равными.
2. Объясни различия HTTP 422, 404 и 503 на примерах этого API.
3. Проведи трёхминутное демо без чтения README: обзор → сравнение → Lab → Project.

Как закрывать экзамен

1. Твои слайды 6 (демо, 165 секунд) и 10 (закрытие, 60 секунд). Демо — самая длинная часть выступления и самая уязвимая.
2. Пять шагов демо держи по порядку из таблицы ниже и вслух называй, что ожидаешь увидеть, до того как это появится на экране.
3. Если что-то не поднялось — не чини Docker при экзаменаторе. Одна фраза «переходим на записанные доказательства» и скриншоты из `defense/site/assets/`.
4. Покажи состояние «нет данных» специально: это доказывает, что интерфейс не выдумывает 0–0.
5. В Lab меняй ровно один ввод, потом Reset. Один фактор за раз — это же правило, что в измерениях.
6. На вопрос «зачем API, а не графики из таблиц» отвечай про размер: миллионы строк не уходят в браузер, SQL и валидация остаются на сервере.
7. Закрывая, назови границы проекта и незакрытые пункты сам — это последнее, что услышит экзаменатор, и честность здесь работает в плюс.

Где смотреть в проекте

Файл в проекте	Что в нём смотреть
`app/api.py`	Контракты эндпоинтов, 422 / 404 / 503, bound-параметры, read-only транзакции и guard на существование таблиц.

Файл в проекте	Что в нём смотреть
`app/static/app.js`	Состояния страницы: отсутствие покрытия, отсутствие встреч и реальный 0–0 — три разных состояния.
`app/static/api-docs.html`	Готовая документация API: открывается на `/api/docs` во время демо.
`scripts/check_live.py`	Проверка живых контрактов и подготовленных выходов — запускается после подъёма стека.
`scripts/browser_check.mjs`	Браузерные проверки реальных сценариев и мобильной раскладки, скриншоты в `artifacts/`.
`scripts/site_check.mjs`	Проверка офлайн-сайта пособия, результат в `defense/site-check.json`.
`tests/test_head_to_head.py`	Перспектива выбранного клуба: голы за и против меняются местами при развороте сравнения.
`tests/test_health.py`	Почему 503 означает «данные или модель не готовы», а не ошибку запроса.
`docs/FRONTEND_HANDOFF.md`	Контракт данных для внешнего фронтенда — доказательство, что presentation отделён от обработки.

Избегай

- Очные ассисты или xG доступны в матчевом источнике.
- Модель обучается заново при каждом движении слайдера.
- Успешный HTTP 200 одной страницы доказывает корректность всех данных.

ATAIKA · 3:45 RECOMMENDED SPEAKING TIME

Инфраструктура и измерения

Область: Compose → readiness → воспроизводимость → время/RAM/диск/рост

Что знать

- Порядок db healthy → loader success → pipeline success → app. Почему depends_on с успешным завершением отличается от простого запуска процесса.
- Named volume базы и bind mounts для CSV, модели и измерений; почему секреты и сырые данные исключены из Git и Docker build context.
- Методика: три повторения, среднее и отдельные результаты, одна изменяемая величина, характеристики ноутбука.
- Полный запуск 31.10 s относится к готовым CSV и образам; это не время первого скачивания и сборки.
- Индекс сравнивается на одной выборке 300 клубов; 25/50/100% эксперименты — отдельная агрегация крупнейшей таблицы.
- Память — максимальное наблюдаемое working set из docker stats, а не непрерывно измеренный истинный пик.
- Что нужно подготовить к защите: данные и образы заранее, рабочий ноутбук, сохранённые результаты, PDF и двухминутное резервное видео.

Что показать

1. Открыть docker-compose.yml и проследить зависимости и mounts без публикации паролей.
2. Показать README/MEASUREMENTS.md: машина, три прогона, диапазон условий и рост данных.
3. Объяснить отличие 31.10 s запуска от 10.872/0.0748 s запросов и от времени импорта одного CSV.

Английская реплика для репетиции

> *Docker Compose coordinates four core services. The database must be healthy, loading and processing must finish successfully, and then the application starts. Source files, the model and measurement results use explicit mounts. We measured timing, observed memory, disk footprint and growth in separate experiments, each repeated three times. Complete cached-source startup averaged 31.10 seconds on an Apple M3 Pro with 18 GiB RAM. The selective index lookup improved by about 145 times, but that result applies to that query and sample. Caches were retained, image builds were excluded and brief memory peaks may have been missed.*

Передача слова: “Taken together, the system is reproducible on the measured setup, while the data and model limitations remain explicit.”

Практика

1. По схеме объясни, что произойдёт, если loader завершится с ошибкой, а база уже healthy.
2. Сравни 25% и 100%: строк в 4 раза больше, загрузка примерно в 4.40 раза дольше; объясни, почему это не универсальный закон.
3. Подними проект по README на другом ноутбуке и запиши наблюдения. Не объявляй эту проверку выполненной до реального запуска.

Как закрывать экзамен

1. Твои слайды 8 и 9 (11:15–15:00) — ты закрываешь содержательную часть, и твоя часть прямо соответствует обязательному пункту «производительность в числах».
2. Каждое число произноси с условиями: 31.10 с — среднее трёх прогонов с готовыми источниками и собранными образами, без скачивания и без сборки.
3. 145.4× называй как результат одного эксперимента на 300 выборочных запросах, а не как ускорение всего приложения. Этот вопрос задают почти всегда.
4. Память описывай методом: максимальная наблюдённая выборка docker stats с интервалом около двух секунд, не гарантированный пик.
5. Рост 25 / 50 / 100% объясняй нелинейностью: 4× строк дали 4.40× загрузки и 3.35× агрегации из-за фиксированных затрат, планов и кэшей.
6. Меняй один фактор за раз — скажи это вслух, это прямое требование протокола измерений из брифа.
7. В конце назови, что осталось: лицензия, независимый запуск на другом ноутбуке, резервное видео и фактический состав участников. Не заявляй их выполненными.

Где смотреть в проекте

Файл в проекте	Что в нём смотреть
`docker-compose.yml`	Порядок запуска: healthcheck базы → успешный loader → успешный pipeline → приложение. Профили для measure и legacy UI.
`docs/MEASUREMENTS.md`	Три прогона, железо (M3 Pro / 18 GiB), метод выборки памяти и все оговорки. Главный документ твоей части.
`docs/ARCHITECTURE.md`	Контейнеры как блоки, стрелки как файлы, строки, SQL и HTTP — структура для слайда архитектуры.
`docs/COURSE_REQUIREMENTS.md`	Таблица требований курса со страницами брифа и статусом каждого пункта.
`measure/benchmark.py`	Эксперимент с индексом: 300 одинаковых выборочных запросов, 145.4× — и почему это не ускорение всего приложения.
`scripts/measure_system.py`	Полный прогон с нуля: старт 31.10 с, loader 12.53 с, pipeline 9.7 с (средние трёх прогонов).

Файл в проекте	Что в нём смотреть
`scripts/report_measurements.py`	Сборка измерений в отчёт — показывает, что числа не вписаны руками.
`docs/AUDIT.md`	Найденные и исправленные дефекты: ответ на вопрос «как вы убедились, что это работает».
`docs/WORK_PACKAGES.md`	Пакеты работ, приёмочные условия и честный список незакрытых внешних пунктов.
`scripts/build_defense.py`	Сборка этого пособия: слайды, роли, PDF и проверка, что выступление ровно 900 секунд.

Избегай

- 31 секунда включает скачивание 353 MiB и сборку образов.
- docker stats гарантирует истинный максимальный расход памяти.
- Одинаковое число коммитов подтверждает одинаковый личный вклад.

Вопросы экзаменатора

Сначала ответь вслух коротко, затем объясни основание и ограничение.

NEDALOZANOVSKA

Why PostgreSQL rather than MongoDB?

Почему PostgreSQL?

The source tables have fixed columns and relational links by player, club, season and competition. PostgreSQL supports those joins, native COPY and indexed lookups with a clear schema. A different database could work, but this choice follows the data shape.

NEDALOZANOVSKA

What identifies one observation?

Что является ключом строки?

For the analytical output it is club ID, season and competition ID. A club's display name is a label, not its identity. We aggregate canonical keys to prevent alias names from creating duplicate observations.

NEDALOZANOVSKA

Why build indices after loading?

Почему индексы после COPY?

Maintaining indices during a bulk load adds work to every inserted row. We import with COPY, then build the required indices and ANALYZE the updated tables so the next pipeline has current planner statistics.

NEDALOZANOVSKA

Is your source openly licensed?

Подтверждена ли лицензия?

We verified the pinned source revision, headers and checksums, but did not establish an explicit upstream licence. We document this as unresolved and exclude raw data from the repository. Public downloadability alone is insufficient.

NEDALOZANOVSKA

What happens if a download is interrupted?

Что будет при обрыве загрузки?

The downloader writes a temporary file and installs it atomically only after checksum and header validation. An interrupted or corrupt download is not accepted as a complete source. Tests exercise these failures using fake HTTP responses.

NEDALOZANOVSKA

How do you handle duplicate match rows?

Как обрабатываются дубли матчей?

Identical league/season/date/home/away fixtures are imported once. Conflicting scores for the same fixture stop replacement before stored match rows are changed. Missing optional input clears old enrichment on the next loader run.

LILLLAZ

Is Champagne Index an official metric or xG?

Это официальный индекс или xG?

No. It is this project's proxy: recorded goals plus assists divided by source matches. A goal with an assist contributes twice. We explain the denominator and do not present it as xG or an official rating.

LILLLAZ

What exactly does the model predict?

Что именно предсказывает модель?

The next consecutive season's Champagne Index minus the current index. It does not predict a match score, a calibrated league position or the causal return from buying a player.

LILLLAZ

Why reject gaps between seasons?

Почему нельзя брать просто следующую строку?

A club may leave a competition and return years later. shift(-1) gives the next recorded row, which is not necessarily next year. We explicitly require a one-year gap and adequate coverage in both seasons.

LILLLAZ

Why use a temporal split?

Зачем хронологический holdout?

A random row split mixes earlier and later seasons and can make historical evaluation overly optimistic. We train on earlier seasons and test on later ones, keeping observations from the same season together.

LILLLAZ

How much better is the model than a baseline?

Насколько модель лучше baseline?

On the same 5,585 held-out rows, MAE is about 0.4856 versus 0.5114 for predicting no change. That is about a five percent reduction in MAE, a modest gain. R-squared is about 0.127, not a percentage of correct predictions.

LILLLAZ

Can you conclude that buying attackers improves performance?

Можно ли утверждать причинный эффект?

No. These are retrospective observational data with confounding and source limitations. A slider changes a model input and shows a learned association, not the outcome of a controlled transfer intervention.

LILLLAZ

Why is the Lab model different from the evaluation model?

Почему две обученные модели?

The evaluation model uses only earlier training data and is scored on held-out later seasons. A separate model is refitted on all eligible data for exploration. Its own training fit is not claimed as independent test performance.

LILLLAZ

Why did the index-position correlation change after the audit?

Почему изменилась корреляция?

The earlier result mixed a partial 25/26 attacking snapshot with full final standings. We now require adequate comparable coverage. The corrected same-season association is about minus 0.793 over 388 observations.

JACOPOSCACCIANOCE

Why have an API instead of plotting raw tables directly?

Зачем API?

The API exposes small prepared outputs under an explicit league and season. This avoids moving millions of raw rows to the browser, keeps SQL and validation on the server and separates presentation from processing.

JACOPOSCACCIANOCE

How are head-to-head goals calculated?

Как считаются голы друг другу?

For each completed meeting, the selected club's perspective determines whether the home or away score is goals for. Reversing the compared clubs swaps their totals. Wins, draws, losses and points are derived from those actual scores.

JACOPOSCACCIANOCE

Does no recorded match mean a 0–0 draw?

Нет данных — это 0–0?

No. No coverage, no recorded meetings and a completed 0–0 draw are different states. The API reports enrichment availability and the interface shows an explicit message instead of inventing a score.

JACOPOSCACCIANOCE

What prevents invalid scenario inputs?

Как защищены входы Lab?

The API rejects non-finite numbers, checks bounds and requires attacking spend not to exceed total spend. The browser also clamps the sliders. Server-side validation remains necessary even when the UI enforces the same rule.

JACOPOSCACCIANOCE

What do HTTP 422, 404 and 503 mean here?

Что означают ошибки API?

422 indicates invalid input, such as selecting the same club twice. 404 means the requested club-season scope is unavailable. 503 indicates temporary data/model unavailability or an incomplete application output state.

JACOPOSCACCIANOCE

What do your tests prove?

Что доказывают тесты?

Regression tests cover known failure cases, live checks validate the prepared outputs and API contracts, and browser checks exercise actual flows and mobile layout. They provide scoped evidence, not a guarantee that every possible bug is absent.

ATAIKA

What starts when you run Docker Compose?

Что запускает Compose?

The database becomes healthy, then the loader must finish successfully, then the processing pipeline must finish, and finally the application starts. The measurement service is on demand and the legacy interface uses an optional profile.

ATAIKA

What does the 31.10-second measurement include?

Что входит в 31.10 секунды?

A mean over three complete starts with prepared source files and existing images: containers are recreated, sources reimported and the model retrained until the API is ready. Network acquisition and image builds are excluded and caches are not flushed.

ATAIKA

Does the index make the whole application 145 times faster?

Всё приложение быстрее в 145 раз?

No. The measured gain is for 300 identical selective club lookups on the raw performance table, comparing index conditions. The frontend reads prepared outputs and a full GROUP BY has a different access pattern.

ATAIKA

Is your memory number a guaranteed peak?

Это гарантированный пик RAM?

It is the largest observed Docker working-set sample during three runs, sampled at roughly two-second intervals. Brief peaks may be missed. We report the method rather than label it a continuous or hardware-independent maximum.

ATAIKA

Why did four times as many rows not give exactly four times the query time?

Почему масштабирование не точно линейное?

Fixed costs, query plans, indexing, caches and hardware influence scaling. In this experiment four times the largest-table rows gave about 4.40 times the loading time and 3.35 times the aggregation time. That does not define a general law.

ATAIKA

What remains before a group submission?

Что ещё нужно для сдачи?

Confirm actual team membership and each person’s contribution, run an independent second-laptop setup, resolve the source licence, rehearse the presentation and record a backup demo. Equal author email counts alone do not demonstrate real group participation.

BCE

What is the main result in one sentence?

Главный результат одним предложением?

The system is reproducible on the measured setup, while historical transfer spending alone has almost no linear relationship with next-season index change and the richer model adds only modest predictive value.

BCE

What is the most important limitation?

Главное ограничение?

The data are retrospective and unevenly covered, the index is a proxy, and associations are not causal effects. Source licence and independent team/laptop validation also remain explicit unresolved requirements.

BCE

How do goals for, goals against and goal difference work in the comparison?

Как в сравнении рассчитываются забитые, пропущенные голы и разница?

GF and GA are season totals rebuilt from completed home/away match scores. GD is GF − GA. They come from the optional football-data.co.uk match enrichment, not from the Champagne Index player totals.

BCE

How are attacking and defensive ranks calculated?

Как рассчитываются атакующий и защитный рейтинги?

Within one league and season, attack rank orders goals scored per match from highest to lowest; defense rank orders goals conceded per match from lowest to highest. SQL RANK gives tied rates the same rank and leaves a gap after ties. They describe scores, not tactics or chance quality.

BCE

Do we have xG or can we estimate it?

Есть ли в данных xG или можем ли мы его оценить?

The source has no provider xG field. The comparison instead shows observed shots and shots on target. A separate estimate multiplies shots on target by the league-season average goals-per-shot-on-target rate; it is an experimental volume proxy with no shot-location or chance-quality input, not xG.

BCE

What is the difference between the Champagne Index and attack rank?

Чем атакующий рейтинг отличается от Champagne Index?

The Champagne Index is recorded player goals plus assists divided by a Transfermarkt matches proxy for a club-season. Attack rank uses actual completed league scorelines, sums team goals and ranks goals per match within the league-season. Their sources, coverage and units differ.

BCE

How did you check the goalkeeper defensive totals?

Как вы проверили вратарские показатели по пропущенным?

We compared Transfermarkt goalkeeper goals-conceded totals with the independent match-result totals on 388 adequately covered top-five club-seasons. They match exactly in 366 (94.3%). Clean sheets match only 269 (69.3%), so the scoreline source remains the basis of league ranks.

BCE

What does the defensive-spend analysis show?

Что показывает анализ расходов на защитников?

The Pearson correlation between defender transfer fees and next-season change in the goalkeeper-source conceded-goal rate is r=0.004047, p=0.426997, n=38,531. The sample does not support a useful linear association. It is descriptive, not causal. A separate match-level check finds teams with a red card concede 0.341 more goals on average in the same match, but match context confounds that association.

BCE

Why keep the player-source defensive values separate from scoreboard goals?

Почему defensive-показатели по игрокам отделены от итогов матчей?

The sources use different records and denominators. Goalkeeper conceded totals agree with scorelines in 94.3% of adequately covered seasons, while clean sheets agree in 69.3%. The UI therefore uses match scores for GF, GA, GD and ranks; player-source totals remain a quality cross-check. Shots and corners are also observed match statistics, not chance-quality measures.

BCE

Is the shot-based estimate the same as xG?

Оценка по ударам — это xG?

No. It multiplies a team's shots on target by the league-season average goals per shot on target. It has no shot-location, distance, body-part, pressure or goalkeeper-position input. It is a rough volume benchmark and must be called an SOT-based proxy, not provider xG.

BCE

What does the Poisson attack/defense rank tell us?

Что показывают Poisson-ранги атаки и обороны?

The model fits attack, defense and a shared home-advantage term to the selected league-season scores. Larger fitted attack and defense parameters mean stronger estimated attack and defense. Its ranks are descriptive and in-sample; the separate chronological RandomForest evaluation is the project's held-out prediction check.

BCE

Did the added defensive features improve the model?

Улучшили ли защитные признаки модель?

On the same chronological split, R^2 moves from 0.1271 with the five-feature baseline to 0.1502 after adding goalkeeper conceded rate, discipline and net spend; MAE moves from 0.4856 to 0.4788 on 5,585 held-out rows. The gain is modest, and it does not isolate a causal effect of defense.

BCE

Do red cards cause more goals to be conceded?

Красные карточки приводят к большему числу пропущенных?

The local sample shows a same-match difference of +0.341 conceded goals per team-match (1,619 sent-off vs 16,195 others; Welch $p < 0.0001$). This is observational: stronger opponents, match state and timing can affect both red cards and goals. It is not a causal estimate.

Порядок 15-минутного выступления

Slide	Owner	Time	What to show
1. The price of beautiful football	nedalozanovska	00:00–01:00	Does incoming transfer spend accompany better attacking output next season?; Separate question: does the index track same-season league finish?; A reproducible data system with measured infrastructure.

Slide	Owner	Time	What to show
2. Know the source	nedalozanovska	01:00–02:30	11 pinned CSV tables · 5.74m local rows; Optional 8,908 completed matches across five leagues; Headers, hashes and atomic acquisition; raw data excluded from Git; Boundary: source licence still unconfirmed.
3. From CSV to the screen	nedalozanovska	02:30–03:45	GET → STORE → PROCESS → SHOW; PostgreSQL 16 + loader + Python pipeline + FastAPI; Compose waits for health and successful completion; Model and measurement artifacts use explicit mounts.
4. Define the observation before fitting	lilllaz	03:45–05:15	Club × season × competition is one observation; Index = (recorded goals + assists) / source matches; Target = next consecutive season index − current index; Exclude inadequate season pairs and competition-unsafe lags.
5. An honest model comparison	lilllaz	05:15–06:30	Earlier seasons train; later seasons test; Test MAE 0.4856 vs zero-change baseline 0.5114; About 5% less absolute error; R^2 = 0.127; Separate all-data model powers retrospective scenarios.
6. See the evidence	jacoposcaccianoce	06:30–09:15	Serie A 24/25 → two clubs → comparison; Season GF / GA / GD: Inter 79 / 35 / +44; Milan 61 / 43 / +18; Attack ranks 1 / 3; defense ranks 2 / 7, by per-match goals; Separate head-to-head: scores 1–2 and 1–1; aggregate goals 2–3; Open Lab → change one input → reset; Project page: sample sizes, methods and measurements.; Shots / shots on target / corners: coverage 8,907 of 8,908 matches; Poisson model ranks are in-sample; the SOT conversion proxy is not xG
7. What the data supports	lilllaz	09:15–10:15	Transfer spend → next attacking change: r = −0.0036; n = 38,531; Defender spend → next conceded-goal change: r = +0.0040; p = 0.427; Same-season index ↔ position: r = −0.793; n = 388; Different targets; these are associations, not interventions.; Same temporal split: R^2 0.127 → 0.150 with conceded rate, discipline and net spend; Red-card difference +0.341 conceded goals; observational, not causal
8. Measure the whole system	Ataika	10:15–12:30	Three repetitions on Apple M3 Pro / 18 GiB; Cached-source startup 31.10 s; 300 lookups: 10.8724 s → 0.0748 s with index; Database 695.5 MiB; source CSVs 356.6 MiB.
9. Growth, memory and failure cases	Ataika	12:30–14:00	25/50/100% of the largest table; 4× rows: 4.40× load time; 3.35× query time; Observed per-container memory, not guaranteed instantaneous peak; 38 regression + 16 live + 15 browser checks.
10. Boundaries and ownership	jacoposcaccianoce	14:00–15:00	Data quality and causal interpretation stay explicit; Source licence and independent laptop validation remain open; Explain the actual work of each real participant; Take questions on any part of the system.

Демо и готовность

Time	Action	Expected / fallback
Before speaking	docker compose up -d; open /api/health and preload the app	ready=true; app/db healthy; loader/pipeline completed Use saved screenshots and the PDF presentation; do not troubleshoot Docker for the whole presentation.
0:00–0:30	Open Overview, Serie A 24/25	20 clubs and a complete-source season Open overview-desktop.png from the evidence folder.
0:30–1:15	Open Inter/Milan comparison	Two recorded meetings (2–3 head-to-head goals) and season GF/GA/GD with league ranks If match source is absent, explain the coverage message and use comparison-desktop.png as the recorded example.
1:15–2:15	Open Lab, change only total spend, then Reset	Scenario response and baseline return; attack budget remains within total Show lab-desktop.png and explain saved-model inference.
2:15–3:00	Open Project → findings / measurements	r, n, MAE/baseline and dated timing evidence with limitations Use the results and measurement slides.

До сдачи

- Каждый объясняет GET → STORE → PROCESS → SHOW без подсказки
- Каждый прошёл свою роль, упражнения и вопросы
- Каждый ответил минимум на два вопроса вне своей роли
- Презентация укладывается в 15 минут; все реальные участники говорят
- Другой участник запустил свежий checkout по README и записал результат
- Подтверждена лицензия первичного источника либо выбран допустимый источник
- Записано и проверено резервное двухминутное видео
- Указаны фактические участники и реальные выполненные ими изменения/проверки

Экзаменационный день

Дата	Формат	Что требуется
12 ноября 2026 CIDS Lecture 15, стр. 37–39	Чекпоинт · 5 минут	Сквозное демо, один видимый результат и первое измеренное время полного прогона. Красивый интерфейс не требуется.
20 / 26 ноября 2026 CIDS Lecture 15, стр. 37–39	Финальная защита · 15 минут + 5 минут вопросов	Говорят все реальные участники. Рекомендованный хронометраж: вопрос и данные 3 мин, архитектура 2, живое демо 3, измерения 3, проблемы 2, вклад 2.

Подготовка машины и материалов

1. За 30 минут: `docker compose up -d --build`, затем открыть `/api/health` и дождаться `ready=true` вместе с завершёнными loader и pipeline.
2. Открыть заранее четыре вкладки: Overview (Serie A 24/25), сравнение Inter / Milan, Lab и страницу Project с числами.
3. Открыть офлайн-копию пособия `defense/site/index.html` и `defense/site/downloads/Presentation.pdf` — они работают без сети и без базы.
4. Проверить, что скриншоты `defense/site/assets/*-desktop.png` на месте: это резерв, если Docker не поднимется.
5. Отключить уведомления, подключить питание, проверить зеркалирование экрана и масштаб шрифта в браузере.
6. Решить заранее, кто ведёт демо и кто держит таймер; таймер есть в `defense/site/presentation.html` (клавиша N — заметки, F — полный экран).

Как отвечать на вопросы

- Отвечай тремя шагами: короткий ответ одним предложением → основание (файл или число) → ограничение.
- Каждое число называй с выборкой и единицей: «r = −0.79 на 388 клуб-сезонах в одном сезоне», а не «корреляция высокая».
- Не знаешь ответа — скажи, где он лежит, и не придумывай: «это в docs/MEASUREMENTS.md, метод измерения памяти описан там».
- Вопрос не по твоей части — передай одной фразой владельцу направления, не пересказывай чужую зону приблизительно.
- Никогда не превращай связь в причину: говори accompanies, is associated with, а не causes или improves.
- Если спросили про слабое место — отвечай прямо и первым. Признанное ограничение выглядит сильнее, чем защищаемая неточность.

Неудобные вопросы: отвечай прямо и первым

Тема	Вопрос	Ответ и где подтверждение
Лицензия первичного источника	Is your data openly licensed?	We pinned the source revision and verified headers and checksums, but we did not establish an explicit reuse licence. We document it as unresolved and we do not redistribute the raw data. Public downloadability is not a licence. `docs/SOURCES.md, docs/COURSE_REQUIREMENTS.md`
Четыре контрибьютора	Who did what in this project?	Describe only the work you can open and explain on screen. Git identities and role cards are not proof of independent contribution, and the repository says so. `docs/WORK_PACKAGES.md, README.md`
Проверка на другом ноутбуке	Did someone else reproduce it?	The run is reproducible on the measured machine. An independent fresh checkout on another laptop has not been recorded yet, so we do not claim it. `docs/MEASUREMENTS.md, docs/WORK_PACKAGES.md`
xG и прокси-метрики	Is this xG?	No. The source has no provider xG field. We show observed shots and shots on target, and a shots-on-target conversion proxy that we label experimental. Poisson attack and defense ratings are in-sample descriptions. `docs/GLOSSARY.md, pipeline/proxy_xg.py, pipeline/power_ratings.py`

Проверенные факты и ограничения

Measure	Value	Explanation
Primary source rows	5,743,186	11 local CSV tables; one legacy metadata table differs from the fresh normalized source.
Completed match enrichment	8,908	Optional, five leagues and seasons 21/22–25/26. Not needed for the primary pipeline.
Spend → next-season change	r = −0.003613	p = 0.478242; n = 38,531 eligible consecutive pairs. A practically tiny association.
Index ↔ final position	r = −0.793285	n = 388 comparable club-seasons. Same-season association; excludes partial index snapshots.
Temporal test R^2	0.127115	Train: 16,074 earlier rows; test: 5,585 rows from season-start year 2021.
Model MAE / baseline MAE	0.485593 / 0.511364	About 5.0% lower MAE. Baseline predicts zero next-season change on the same test rows.
Complete cached-source start	31.10 s	Mean of three runs on Apple M3 Pro / 18 GiB. Download and image build excluded; caches retained.

Measure	Value	Explanation
Selective index lookup speedup	145.4×	300 identical club lookups: 10.8724 s without index, 0.0748 s with index. Not every query gets this gain.
Score-derived league comparison	GF / GA / GD + 2 ranks	Serie A 24/25: Inter 79/35/+44 · attack #1 · defense #2; Milan 61/43/+18 · #3/#7. Per-match goals, league-season ranks.
xG coverage in loaded match source	Not available	No xG field exists in the loaded match-results schema. We do not infer expected goals from final scores.
Goalkeeper GA matches scoreboard	366 / 388 exact · 94.3%	Adequately covered top-five club-seasons; Transfermarkt goalkeeper totals cross-checked against actual completed-match league scores.
Clean sheets match scoreboard	269 / 388 exact · 69.3%	Primary-source clean-sheet totals are less consistent, so the comparison does not use them as a league defensive rank.
Defensive spend → next GA change	r = 0.004047	p = 0.426997; n = 38,531 eligible consecutive pairs. No useful linear association in this snapshot.
Shot and corner coverage	8,907 / 8,908 matches	Shots, shots on target and corners; team comparison uses the exact available-match denominator.
Poisson attack/defence fits	484 team-seasons · 25 league-seasons	Descriptive ratings fitted on the same season scores; not an out-of-sample forecast.
Attack-only → augmented model R^2	0.1271 → 0.1502	Same chronological split and 5,585 held-out observations; augmented features add conceded-goal rate, discipline and net spend.
Red card association	+0.341 conceded goals / team-match	1,619 sent-off vs 16,195 other team-matches; Welch $p < 0.0001$. Descriptive and confounded, not causal.
SHAP · leading feature	Champagne Index · 0.205 mean |SHAP|	Held-out augmented model. Explains this fitted model, not football causally.

Первичный источник закреплён по версии, но лицензия не подтверждена. Это открытый пункт, который нельзя закрыть одной ссылкой на публичную загрузку.